
Eficiência Unimodal em Produção: Uma alternativa a Sistemas de Scores Bancários Legados via Transaction Transformers

Iago Garcia Vargas
Universidade Federal de Uberlândia
iagogarcia@ufu.br

Abstract

Prever a propensão de clientes a produtos financeiros é crucial no setor bancário, mas abordagens multimodais recentes impõem altos custos computacionais e complexidades regulatórias. Propomos o Transaction Transformer, uma abordagem unimodal escalável que opera exclusivamente sobre sequências brutas de transações. O modelo utiliza um Temporal Positional Encoding (TPE) senoidal para tratar intervalos cronológicos irregulares e pré-treinamento via Masked Transaction Modeling (MTM). Para mitigar o desbalanceamento extremo de classes, integramos a Sigmoid Focal Loss com suavização de rótulos e amostragem ponderada. Avaliada sob restrição de recursos no subconjunto MBD-mini (10% dos dados), a extração por embeddings isolados atingiu ROC-AUC média de 0,7862 no teste holdout. Integrada a sistemas legados, a arquitetura híbrida obteve 0,7831 com altíssima estabilidade. Tais resultados superam os baselines XGBoost (0,6762) e regressão clássica (0,7242) sob o mesmo rigor metodológico, validando a eficiência unimodal e viabilizando a modernização de sistemas de score com baixo custo de inferência, sem fusões multimodais custosas.

1 Introdução

A predição de propensão à aquisição de produtos bancários é central para o gerenciamento de relacionamento com clientes (*Customer Relationship Management*, CRM) em instituições financeiras. Abordagens tradicionais agregam o histórico transacional em vetores estáticos de tamanho fixo para treinar modelos baseados em árvores de decisão impulsionadas por gradiente [5]. Essa metodologia, contudo, desconsidera a estrutura temporal e sequencial das transações diárias dos clientes.

Modelos baseados em Transformers [1] e o paradigma de pré-treinamento auto-supervisionado (*pre-train/fine-tune*) [2] atenuam essa limitação ao gerarem representações contextualizadas e transferíveis a partir de dados sequenciais. Esse conceito foi estendido com sucesso para visão computacional (MAE [3]) e para sequências de eventos bancários (CoLES [4]).

Embora propostas recentes explorem *frameworks* multimodais complexos para integrar geolocalização e logs de texto [6], sua aplicação em sistemas produtivos de *scoring* enfrenta restrições severas: falta de infraestrutura de coleta unificada, alto custo de processamento em GPUs e regulações estritas de privacidade sobre dados não estruturados.

Diante disso, otimizar o sinal preditivo contido apenas no histórico transacional estruturado surge como uma alternativa escalável. Neste trabalho, defendemos a *hipótese da eficiência unimodal e amostral*: modelos sequenciais profundos especializados em dados transacionais isolados podem rivalizar com abordagens multimodais complexas, mesmo sob restrição de dados e computação, sendo uma alternativa em casos de restrições computacionais. Para isso, introduzimos o **TransactionTransformer**, projetado para lidar com séries temporais bancárias irregulares e heterogêneas. Nossas contribuições são: (i) o uso do *Masked Transaction Modeling* (MTM), que mascara 15% das

transações e as reconstrói via entropia cruzada e MSE; (ii) o aplicação de um *Temporal Positional Encoding* (TPE) senoidal baseado em deltas absolutos de dias para capturar sazonalidades reais; (iii) um *framework* de regularização integrado (*Focal Loss*, suavização de rótulos e amostragem ponderada); (iv) uma abordagem híbrida de transferência via projeção PCA para *deploy* de baixo custo em sistemas legados; e (v) a validação empírica de que o modelo atinge desempenho competitivo mesmo treinado sob severa restrição amostral (10% do *benchmark* MBD-mini).

2 Conjunto de Dados

Utilizou-se o *Multimodal Banking Dataset* (MBD-mini) [6], correspondente a um subconjunto fixo de 10% da base original. O conjunto processado contempla 38.764.930 transações estruturadas de 100.224 clientes únicos (média de 12,0 janelas/cliente), extraíndo 11 atributos categóricos e 5 contínuos. A tarefa consiste em prever se o cliente adquirirá um dos quatro produtos bancários independentes no mês subsequente (classificação binária multirrótulo). O histórico estruturado em 1.202.688 janelas mensais apresenta severo desbalanceamento: *target_1* (0,45%), *target_2* (0,05%), *target_3* (0,38%) e *target_4* (0,25%). O particionamento respeita a divisão nativa do *benchmark*: *folds* 0–2 para treinamento (60.147 clientes, 721.764 janelas); *fold* 3 para validação (20.017 clientes); e *fold* 4 mantido como teste fixado (*holdout*, 20.060 clientes).

3 Método

O *TransactionTransformer* processa dados em três fases fundamentais: (1) engenharia de atributos para correção de assimetria; (2) pré-treinamento auto-supervisionado via *Masked Transaction Modeling* (MTM); e (3) ajuste fino supervisionado multirrótulo ou integração a arquiteturas híbridas via subespaços lineares.




Figure 1: Metodologia e Arquitetura Proposta.

3.1 Pré-processamento e Transformações de Domínio

Os valores brutos das transações ($x \in \mathbb{R}$) apresentam caudas pesadas. Para estabilizar os gradientes e corrigir descontinuidades de valores frequentes, aplicamos uma transformação logarítmica simétrica e um mapeamento não-linear baseado em quantis:

$$x_{\log} = \text{sign}(x) \cdot \log(1 + |x|), \quad G(x_{\log}) = F_{\mathcal{N}}^{-1}(F_X(x_{\log})) \quad (1)$$

onde F_X é a distribuição acumulada empírica (estimada via 1.000 quantis) e $F_{\mathcal{N}}^{-1}$ é a função quantil da normal padrão. O atributo final x_{scaled} possui média zero e variância unitária. Codificamos o dia da semana (d_w) e do mês (d_m) em componentes trigonométricas bidimensionais (seno e cosseno), gerando um vetor expandido contínuo $\mathbf{z}_{\text{cont}} \in \mathbb{R}^5$ que preserva a ciclicidade temporal.

3.2 Arquitetura do Modelo: TransactionTransformer com TPE Senoidal

A fusão das modalidades mapeia independentemente cada um dos $K = 11$ atributos categóricos c_i em um embedding $\mathbf{E}_i(c_i) \in \mathbb{R}^{16}$. A representação unificada do evento $\mathbf{x}_{\text{event}}$ concatena esses embeddings a $\mathbf{z}_{\text{cont}}$, sendo projetada linearmente para o espaço latente ($d_{\text{model}} = 128$) via uma projeção $\mathbf{W}_0$ ativada por GELU.

Devido à irregularidade cronológica bancária, codificações posicionais ordinais falham. Introduzimos o **Temporal Positional Encoding** (TPE) operando sobre o delta temporal em dias Δt_j :

$$\text{TPE}(j, 2k) = \sin\left(\frac{\Delta t_j}{10000^{2k/d_{\text{model}}}}\right), \quad \text{TPE}(j, 2k+1) = \cos\left(\frac{\Delta t_j}{10000^{2k/d_{\text{model}}}}\right) \quad (2)$$

Um token de classificação $\mathbf{x}_{[\text{CLS}]}$ é prefixado à sequência de eventos ($L = 512$). A rede possui $N = 3$ camadas Transformer com $H = 4$ cabeças de atenção e formulação *Pre-LayerNorm*.




Figure 2: Arquitetura proposta.

3.3 Pré-treinamento e Estratégias de Ajuste Fino

Pré-treinamento MTM: Durante 20 épocas, mascaramos 15% das posições. A partir do estado oculto $\mathbf{h}_m$, cabeças lineares reconstroem a transação original minimizando:

$$\mathcal{L}_{MTM} = \frac{1}{K} \sum_{i=1}^K \text{CE}(\mathbf{W}_{c_i} \mathbf{h}_m, \mathbf{y}_{c_i}) + \lambda \cdot \text{MSE}(\mathbf{W}_z \mathbf{h}_m, \mathbf{z}_{cont}) \quad (3)$$

Estratégia 1 (Ajuste Fino): Acopla-se um MLP ($128 \rightarrow 64 \rightarrow 4$) sobre $\mathbf{h}_{[\text{CLS}]}$ com taxas de aprendizado discriminativas ($\eta_{\text{Encoder}} = 5 \times 10^{-6}$, $\eta_{\text{MLP}} = 1 \times 10^{-4}$). O desbalanceamento é mitigado via suavização de rótulos ($\varepsilon = 0,05$) e *Focal Loss* ($\gamma = 2,0$, $\alpha_t = 0,75$).

Estratégia 2 (Híbrida para Sistemas Legados): O codificador é congelado. O *embedding* $\mathbf{h}_{[\text{CLS}]}$ é projetado via PCA para $\mathbf{v} \in \mathbb{R}^{32}$ (retendo 88,72% da variância) e concatenado a 44 atributos estatísticos manuais. O vetor $\mathbf{x}_{\text{hybrid}} \in \mathbb{R}^{76}$ alimenta modelos clássicos.

4 Resultados Experimentais e Discussões

O monitoramento do MTM revela rápida convergência: $\mathcal{L}_{\text{MTM}}$ estabiliza-se em 0,70, a Entropia Cruzada decresce de 2,40 para 0,55, e o MSE cai para 0,16, demonstrando a internalização de dependências estruturais e numéricas. A comparação entre o treinamento *Scratch* e as variantes de *Fine-Tuning*, com Codificação Posicional Temporal (*TPE*) ou puramente sequencial (*PE seq.*), destaca o poder regularizador do MTM aliado à percepção temporal (Fig. 4). O modelo Transformer (Fine-Tuned, TPE) obteve boa generalização, alcançando ROC-AUC média de 0,7852, superando a variante *Scratch* (0,7674) e a puramente sequencial *PE seq.* (0,7664). Enquanto o *Scratch* apresenta rápida memorização e overfitting na 3ª época, as variantes pré-treinadas apresentam dinâmica estável, confirmando que o contexto temporal gera representações mais robustas.



Figure 3: Convergência das Perdas (MTM).




Figure 4: Fine-Tuned (TPE) vs Scratch.

Table 1: Capacidade de generalização das arquiteturas avaliadas (ROC-AUC de teste, Média $\pm$ Desvio Padrão).

Modelo / Arquitetura	t_1	t_2	t_3	t_4	Média	Melhor Época
Emb Only (LR)	$0,6901 \pm 0,0076$	$0,8206 \pm 0,0162$	$0,7621 \pm 0,0112$	$0,8720 \pm 0,0064$	$0,7862 \pm 0,0064$	—
Transformer (Fine-Tuned, TPE)	$0,6878 \pm 0,0130$	$0,7836 \pm 0,0488$	$0,7847 \pm 0,0152$	$0,8846 \pm 0,0079$	$0,7852 \pm 0,0178$	Época 20
Hybrid (LR)	$0,6870 \pm 0,0060$	$0,8285 \pm 0,0079$	$0,7586 \pm 0,0057$	$0,8583 \pm 0,0042$	$0,7831 \pm 0,0027$	—
Transformer (Scratch)	$0,7107 \pm 0,0135$	$0,6844 \pm 0,0165$	$0,7893 \pm 0,0119$	$0,8852 \pm 0,0115$	$0,7674 \pm 0,0056$	Época 3
Transformer (PE seq.)	$0,6930 \pm 0,0133$	$0,7321 \pm 0,0326$	$0,7508 \pm 0,0135$	$0,8896 \pm 0,0097$	$0,7664 \pm 0,0117$	—
Reg. Logística (Manual)	$0,6436 \pm 0,0000$	$0,8870 \pm 0,0000$	$0,6396 \pm 0,0000$	$0,7264 \pm 0,0000$	$0,7242 \pm 0,0000$	—
Random Forest	$0,6166 \pm 0,0000$	$0,8011 \pm 0,0000$	$0,6595 \pm 0,0000$	$0,7428 \pm 0,0000$	$0,7050 \pm 0,0000$	—
XGBoost	$0,6282 \pm 0,0000$	$0,6505 \pm 0,0000$	$0,6165 \pm 0,0000$	$0,8098 \pm 0,0000$	$0,6762 \pm 0,0000$	—

O desempenho da configuração Emb Only (LR), que alcançou a maior ROC-AUC média global ($0,7862 \pm 0,0064$), evidenciando que o pré-treinamento MTM é autossuficiente para extrair representações de alta qualidade sem fine-tuning do encoder. Por sua vez, a abordagem híbrida demonstrou sinergia técnica para deploy: embora sua média ($0,7831$) seja ligeiramente inferior aos embeddings puros, o Hybrid (LR) apresentou a maior consistência estatística do estudo ($\pm 0,0027$). Em relação ao estado da arte, Mollaev et al. [6] reportaram $\sim 0,78$ no MBD completo usando frameworks multimodais massivos. Nossos resultados apontam competitividade na mesma magnitude utilizando apenas 10% dos dados e estritamente na modalidade transacional.

5 Conclusão

O **TransactionTransformer** valida a eficiência unimodal via MTM e TPE, modelando com eficácia trajetórias irregulares. A extração de atributos via codificador congelado consolidou-se como alternativa para deploy em infraestruturas legadas ($0,7862$ de ROC-AUC com embeddings isolados e $0,7831$ no modelo híbrido), superando baselines clássicos sem incorrer no alto custo de pipelines multimodais e atendendo aos requisitos de latência do setor financeiro.

References

- [1] A. Vaswani et al. Attention is all you need. *NeurIPS*, 2017.
- [2] J. Devlin et al. BERT: Pre-training of deep bidirectional transformers. *NAACL-HLT*, 2019.
- [3] K. He et al. Masked autoencoders are scalable vision learners. *CVPR*, 2022.
- [4] D. Babaev et al. CoLES: Contrastive learning for event sequences. *SIGMOD*, 2022.
- [5] G. Ke et al. LightGBM: A highly efficient gradient boosting decision tree. *NeurIPS*, 2017.
- [6] D. Mollaev et al. Multimodal banking dataset. *Sber AI Lab*, arXiv:2409.17587, 2024.