

Eficiência Unimodal em Produção: Uma alternativa a Sistemas de Scores Bancários Legados via Transaction Transformers

Agenda

01

O Problema

02

Hipótese

03


Metodologia

04

Resultados

05

Conclusões



01

O Problema


Transações Financeiras

A predição de propensão é central para o CRM. Modelos tradicionais tendem a ignorar a estrutura sequencial das transações.

Abordagens multimodais recentes impõem custos computacionais severos e enfrentam rígidas regulações de privacidade sobre dados não estruturados.


Alternativa: Restrição de custo, latência e urgência para colocar em produção?






02

Hipótese




**"Modelos sequenciais profundos
especializados em dados
transacionais isolados podem
rivalizar com abordagens
multimodais complexas, sendo uma
viabilidade para restrições de
infraestrutura."**




03

Metodologia



Metodologia



Base de Dados

38.7M

Transações Estruturadas

100k+

Clientes Únicos

- Uso de **10%** do dataset original.
 - target_1: 0,45% positivos
 - target_2 0,05% positivos
 - target_3 0,38% positivos
 - target_4 0,25% positivos

Fase 1: Transformações de Domínio


- **Correção de Assimetria**

Valores monetários brutos possuem caudas pesadas. Para estabilizar a descida de gradiente, aplicamos uma transformação logarítmica simétrica.


- **Codificação Cíclica**

Dias da semana e dias do mês são dados categóricos ordinais com características circulares (o fim do mês conecta-se ao início). Mapeamento para componentes trigonométricas (seno e cosseno) para gerar um vetor expandido que preserva a ciclicidade.

Arquitetura




Arquitetura




Arquitetura

Fase 1 — Pré-treino MTM (auto-supervisionado)



Fase 2 — Classificação (fine-tuning)



Temporal Positional Encoding (TPE)

Codificações posicionais ordinais clássicas falham em eventos bancários devido à alta irregularidade temporal das transações. Usamos o TPE operando diretamente sobre o delta temporal contínuo em dias.

$$\text{TPE}(j, 2k) = \sin\left(\frac{\Delta t_j}{10000^{2k/d_{\text{model}}}}\right), \quad \text{TPE}(j, 2k + 1) = \cos\left(\frac{\Delta t_j}{10000^{2k/d_{\text{model}}}}\right)$$

Fase 2: Masked Transaction Modeling

- Ocultamos aleatoriamente 15% das transações.
- O modelo reconstrói a transação otimizando a perda conjunta de atributos categóricos (Cross-Entropy) e contínuos (MSE).
- A convergência é rápida (estabilização em 20 épocas), internalizando dependências estruturais numéricas.

$$\mathcal{L}_{\text{MTM}} = \frac{1}{K} \sum_{i=1}^K \text{CE}(\mathbf{W}_{c_i} \mathbf{h}_m, \mathbf{y}_{c_i}) + \lambda \cdot \text{MSE}(\mathbf{W}_z \mathbf{h}_m, \mathbf{z}_{cont})$$

Estratégias de Implementação



Estratégia 1: Ajuste Fino

- MLP de classificação diretamente no token CLS. Utilizamos taxas de aprendizado discriminativas para preservar a representação do encoder.
- O desbalanceamento multirrótulo é mitigado via integração de **Sigmoid Focal Loss** e Suavização de Rótulos (Label Smoothing).

Estratégia 2: Deploy Híbrido

- O encoder transformer atua apenas como extrator congelado. Seu embedding latente é projetado via PCA (retendo 88,7% da variância) para um vetor menor.
- Este estado é concatenado a estatísticas manuais tradicionais e alimenta um modelo clássico de regressão para deploy de baixo custo.

Resultados



Resultados

Table 1: Capacidade de generalização das arquiteturas avaliadas (ROC-AUC de teste, Média $\pm$ Desvio Padrão).

Modelo / Arquitetura	t_1	t_2	t_3	t_4	Média	Melhor Época
Emb Only (LR)	0,6901 $\pm$ 0,0076	0,8206 $\pm$ 0,0162	0,7621 $\pm$ 0,0112	0,8720 $\pm$ 0,0064	0,7862 $\pm$ 0,0064	—
Transformer (Fine-Tuned, TPE)	0,6878 $\pm$ 0,0130	0,7836 $\pm$ 0,0488	0,7847 $\pm$ 0,0152	0,8846 $\pm$ 0,0079	0,7852 $\pm$ 0,0178	Época 20
Hybrid (LR)	0,6870 $\pm$ 0,0060	0,8285 $\pm$ 0,0079	0,7586 $\pm$ 0,0057	0,8583 $\pm$ 0,0042	0,7831 $\pm$ 0,0027	—
Transformer (Scratch)	0,7107 $\pm$ 0,0135	0,6844 $\pm$ 0,0165	0,7893 $\pm$ 0,0119	0,8852 $\pm$ 0,0115	0,7674 $\pm$ 0,0056	Época 3
Transformer (PE seq.)	0,6930 $\pm$ 0,0133	0,7321 $\pm$ 0,0326	0,7508 $\pm$ 0,0135	0,8896 $\pm$ 0,0097	0,7664 $\pm$ 0,0117	—
Reg. Logística (Manual)	0,6436 $\pm$ 0,0000	0,8870 $\pm$ 0,0000	0,6396 $\pm$ 0,0000	0,7264 $\pm$ 0,0000	0,7242 $\pm$ 0,0000	—
Random Forest	0,6166 $\pm$ 0,0000	0,8011 $\pm$ 0,0000	0,6595 $\pm$ 0,0000	0,7428 $\pm$ 0,0000	0,7050 $\pm$ 0,0000	—
XGBoost	0,6282 $\pm$ 0,0000	0,6505 $\pm$ 0,0000	0,6165 $\pm$ 0,0000	0,8098 $\pm$ 0,0000	0,6762 $\pm$ 0,0000	—

Conclusões

- O MTM atua como um poderoso regularizador contra esquecimento catastrófico.
- O TPE senoidal assimila com excelência os espaçamentos irregulares das transações de clientes.
- A arquitetura híbrida consolida-se como uma alternativa barata: une o poder sequencial profundo aos baixos custos de latência de infraestruturas legadas.



Obrigado!

